

基于 CNN-LSTM 混合神经网络模型的短期负荷预测方法

陆继翔^{1,2}, 张琪培¹, 杨志宏^{1,2}, 涂孟夫^{1,2}, 陆进军^{1,2}, 彭 晖^{1,2}

(1. 南瑞集团有限公司(国网电力科学研究院有限公司), 江苏省南京市 211106;

2. 智能电网保护和运行控制国家重点实验室, 江苏省南京市 211106)

摘要:为了更好地挖掘海量数据中蕴含的有效信息,提高短期负荷预测精度,针对负荷数据时序性和非线性的特点,提出了一种基于卷积神经网络(CNN)和长短期记忆(LSTM)网络的混合模型短期负荷预测方法,将海量的历史负荷数据、气象数据、日期信息以及峰谷电价数据按时间滑动窗口构造连续特征图作为输入,先采用 CNN 提取特征向量,将特征向量以时序序列方式构造并作为 LSTM 网络输入数据,再采用 LSTM 网络进行短期负荷预测。使用所提方法对江苏省某地区电力负荷数据进行预测实验,实验结果表明,文中所提出的预测方法比传统负荷预测方法、随机森林模型负荷预测模型方法和标准 LSTM 网络负荷预测方法具有更高的预测精度。

关键词:短期负荷预测;卷积神经网络;长短期记忆网络;卷积神经网络-长短期记忆网络混合模型

0 引言

由于电能难以大量存储以及电力需求时刻变化等特点,要求系统发电应与负荷的变化实现动态平衡。提高负荷预测准确率有利于提高发电设备的利用率和经济调度的有效性^[1],特别是市场化改革后,电力供需将通过实时交易实现平衡,短期负荷预测精度越来越重要。另一方面,随着电网规模不断扩大,设备不断增多,信息化程度不断提高,智能电网调度系统对负荷的采集频率和数据准确性也不断提升,为负荷特性分析和负荷预测提供了高质量、海量化的数据集,为深度学习的使用提供了数据基础。

电力负荷数据具有时序性和非线性的特点,围绕其特点,国内外一般对短期电力负荷预测的模型研究分为两类,一类是时间序列分析方法,例如回归分析法^[2]、指数平滑模型法^[3]、卡尔曼滤波法^[4]、多元线性回归法^[5]、傅里叶展开法模型^[6]和自回归积分滑动平均(ARIMA)模型^[7-8]等,基本思想是从随机时间序列的过去负荷值及现在负荷值来预测未来负荷值,它的优点在于考虑了数据的时序性关系,缺点在于对非线性关系数据的预测能力有限;第二类是机器学习分析方法,例如文献^[9-11]中使用了反

向传播(BP)神经网络来预测,文献^[12]中用到了灰色投影和随机森林算法,文献^[13]使用了深度信念网络预测,文献^[14]使用了多核支持向量机算法来回归预测,还有专家系统法^[15]预测等。这些算法共同存在的问题在于缺少对时序数据时间相关性的考虑,需要人为添加时间特征来保证预测的结果。被用于语言模型^[16]、机器翻译^[17]、语音识别^[18]等领域的长短期记忆(LSTM)网络是一种有效的非线性循环神经网络,由于兼顾数据的时序性和非线性关系,被逐渐运用在负荷预测领域。LSTM 网络模型虽然可以充分反映输入时间序列数据中的长期历史过程^[19-20],但它并不能挖掘非连续数据之间蕴含的有效信息和潜在关系。

为了提高短期负荷预测精度,本文提出了一种基于卷积神经网络(CNN)和 LSTM 网络的混合模型短期负荷预测方法,简称 CNN-LSTM 网络混合模型。它结合了 CNN 和 LSTM 网络的各自特点,利用负荷预测的先验知识,将海量的历史负荷数据、气象数据、日期信息以及峰谷电价数据按时间滑动窗口构造连续特征图作为输入,先采用 CNN 有效地提取特征图中连续数据之间和非连续数据之间的潜在关系形成特征向量,然后将特征向量以时序序列方式构造并作为输入数据,再采用 LSTM 网络进行短期负荷预测。与仅使用 LSTM 网络模型相比,由于 CNN-LSTM 网络混合模型中使用了 CNN 模

收稿日期:2018-10-12;修回日期:2019-01-20。

上网日期:2019-02-26。

国家重点研发计划资助项目(2017YFB0902600)。

<http://www.aeps-info.com> 131

型提取时序数据潜在特征,为 LSTM 网络模型提供大量的有效输入数据,从而提高了预测准确率。

1 负荷影响因素

文献[21]指出,通过比较发现,使用神经网络模型处理问题时虽然可以适应于各种任务且简单易用,但其效果只是接近或者达到传统方法,其部分原因在于神经网络模型中加入先验知识还比较少,在建立合适的神经网络模型时加入恰当的先验知识,可以加快模型收敛,提高模型实际效果。在神经网络模型中运用先验知识在自然语言处理[21]和体态与手势感知[22],显著提高了识别准确率。

本文采用了相应的负荷预测先验知识,将负荷影响因素作为输入参数统一考虑。传统方法将短期负荷预测影响因素主要归纳为三类:最近负荷或相似日负荷、气象信息、日期类型。文献[23]提出了一个电力负荷的函数如式(1)所示。

$$L(t) = L_n(t) + L_w(t) + L_s(t) + L_r(t) \quad (1)$$

式中: $L(t)$ 为 t 时刻的实际负荷; $L_n(t)$ 为 t 时刻的正常或趋势负荷, $L_n(t)$ 应该满足正态分布; $L_w(t)$ 为 t 时刻的天气因素所带来的负荷波动; $L_s(t)$ 为 t 时刻的一些特殊事件所引起的负荷波动,如节假日等; $L_r(t)$ 为 t 时刻随机产生的负荷波动,值较小, $L_r(t)$ 作为负荷预测的噪音,影响较小,也无法控制,通常忽略它。由式(1)所知,可以通过提高 $L_n(t)$ 、 $L_w(t)$ 和 $L_s(t)$ 预测的准确度来提高整体预测的准确度。

对于负荷趋势,有学者使用去年今天的实际负荷,加上去年到今年的负荷累计,得到今年今天的负荷趋势。但由于该方法准确率不高,而且一年间的负荷变化非线性;还有使用最近连续几天的负荷作为参数,通过自回归模型得到当天的负荷趋势,好处在于负荷本身在一段时期是稳定渐变的,不会发生突变,本文利用深度学习来决定选取最近连续一周同一时刻的负荷,并考虑到年负荷变化趋势,将一年前相同日期下同一时刻的负荷一并作为参数获得的负荷趋势 $L_n(t)$ 。

气象因素对于短期负荷预测有着至关重要的影响。其中,常见的影响因素是温度,其次还有湿度、风力、天气类型等。炎热的夏季、寒冷的冬季都会使负荷发生急剧变化。因此,使用气象预测多种因素数据来决定天气影响负荷 $L_w(t)$ 。

日期类型是短期预测的另一个重要影响因素,事实上,目前中国城市用电负荷还是以工业用电负荷为主,非工作日(节假日、周六和周日)的电力负荷

量比工作日(周一至周五)有显著减少。本文将日期类型列入影响负荷预测结果的因素之一。使用日期类型因素来决定特殊事件影响负荷 $L_s(t)$,如假期、周末等。本文使用数字1~7表示周一至周日,考虑到深层神经网络参数需要反向反馈,将工作日与节假日分别用1和2表示。

除此之外,将电价的经济调节因素也作为负荷影响因素考虑。由于工业用电负荷在总负荷的90%左右,因此本文将工业电价因素作为输入,使用1,2和3分别代表谷、平和峰时电价,也反映了价格比例。

本文将原始负荷数据、气象数据、日期因素和峰谷电价因素作为模型训练的输入,如表1所示。

表1 影响因素汇总
Table 1 Summary of impact factors

影响因素	特征	描述
历史数据	$L(d-n, t)$	前 n 天 t 时刻负荷值
	$L(\text{year}-1, t)$	前一年 t 时刻负荷值
日期因素	周日期	周一到周日
	工作日/节假日	工作日/节假日
气象因素	气温	未来一天, t 时刻预测气温
	湿度	未来一天, t 时刻预测湿度
	风速	未来一天, t 时刻预测风速
	风向	未来一天, t 时刻预测风向
	降雨可能性	未来一天, t 时刻预测降雨可能性
	气压	未来一天, t 时刻预测气压
经济因素	峰	峰时电价
	平	平时电价
	谷	谷时电价

2 CNN-LSTM 网络混合模型

2.1 CNN 模型

CNN 模型是近年来深度学习领域研究最热门、应用最广泛的模型之一。它采用局部连接和共享权值的方式,直接从原始数据中通过卷积层和池化层交替使用来获取有效表征,自动提取数据的局部特征,并建立稠密、完备的特征向量[24],本文使用CNN来提取数据特征。

2.2 LSTM 网络模型

LSTM 网络是一种改进的时间循环神经网络(RNN)。它被提出后也进行了改良,增加了额外的遗忘门[25-26]。改良后的LSTM网络解决了在模型训练中“梯度消失”的问题,可以学习时间序列长短依赖信息,是目前最成功的RNN架构,在许多场景中获得应用。其网络基本单元如图1所示。




图1 LSTM网络的基本单元
Fig.1 Basic unit of LSTM network

LSTM网络的基本单元中包含遗忘门、输入门和输出门^[26]。遗忘门中输入 x_t 与状态记忆单元 S_{t-1} 、中间输出 h_{t-1} 共同决定状态记忆单元遗忘部分。输入门中的 x_t 分别经过sigmoid和tanh函数变化后共同决定状态记忆单元中保留向量。中间输出 h_t 由更新后的 S_t 与输出 o_t 共同决定,计算公式如式(2)~式(7)所示。

$$f_t = \sigma(W_{fx}x_t + W_{fh}h_{t-1} + b_f) \quad (2)$$

$$i_t = \sigma(W_{ix}x_t + W_{ih}h_{t-1} + b_i) \quad (3)$$

$$g_t = \phi(W_{gx}x_t + W_{gh}h_{t-1} + b_g) \quad (4)$$

$$o_t = \sigma(W_{ox}x_t + W_{oh}h_{t-1} + b_o) \quad (5)$$

$$S_t = g_t \odot i_t + S_{t-1} \odot f_t \quad (6)$$

$$h_t = \phi(S_t) \odot o_t \quad (7)$$

式中: f_t, i_t, g_t, o_t, h_t 和 S_t 分别为遗忘门、输入门、输入节点、输出门、中间输出和状态单元的状态; $W_{fx}, W_{fh}, W_{ix}, W_{ih}, W_{gx}, W_{gh}, W_{ox}$ 和 W_{oh} 分别为相应门与输入 x_t 和中间输出 h_{t-1} 相乘的矩阵权重; b_f, b_i, b_g, b_o 分别为相应门的偏置项; $\odot$ 表示向量中元素按位相乘; σ 表示sigmoid函数变化; ϕ 表示tanh函数变化。

2.3 CNN-LSTM网络混合模型

本文提出的CNN-LSTM网络混合模型是以时间序列特征图作为网络的输入。负荷历史数据、气象信息、节假日信息和电价信息等数据实际上都是相互独立的时间序列。为了耦合这些影响负荷的特征信息,本文参考自然语言处理中的词向量表示方法,将某一时刻的负荷值由与其相关的特征串联成向量表示,进而形成一个全新的时间序列数据。每一时刻的历史负荷均由与其相关的特征共同表示。然后再使用滑动窗口方式依次将输入的时间序列数据生成特征图,为了方便后续网络计算,滑动窗口宽设为16条记录,步长设为1,单位特征图的尺寸为 16×16 ,输入的特征图也按时间序列排列,如图2所示。其中 t 为该坐标轴以时间为尺度; T 为间隔为5 min的某一具体时刻; $T+n$ 为 T 时刻往后 n 个5 min间隔的时刻。




图2 CNN-LSTM网络模型输入数据结构
Fig.2 Structure of input data in CNN-LSTM network model

本文提出的CNN-LSTM网络混合模型结构如图3所示,CNN-LSTM网络混合模型主要有两部分组成,CNN部分主要负责特征提取,LSTM网络主要负责负荷预测。CNN设计有4层卷积层(Conv2D),卷积核数目依次设为32,64,128和256。CNN可根据内核的大小,从输入的时间序列数据中提取许多有用的特征,即CNN可通过将内核大小设置得更小或更大来提取反映多变量时间序列数据的更窄或更宽时间段的特征。国家电网有限公司的短期负荷预测通常需要在当天预测第二天当地总负荷,预测频率为每15 min一个负荷估计值,即预测第二天的96个负荷节点。考虑到目前设备采集的短期负荷实际数据是每5 min一个点,为充分利用现有负荷数据,本文将卷积核大小设为 3×3 ,在池化层(MaxPooling2D)中,池大小为2,通过卷积层中的特征映射使用最大池化来减小输出维度大小,经过连续4次卷积和最大池化操作,得到 $2 \times 2 \times 256$ 的三维向量数组,其中256为通道数。然后执行扁平层操作(Flatten),将三维向量数组压成长度为1 024的一维向量数组,作为全局特征提取。




图3 CNN-LSTM网络混合模型
Fig.3 Hybrid model of CNN-LSTM network

在 LSTM 网络部分,经过实验发现通过增加 LSTM 网络单元来增加模型的深度有助于提高模型的预测能力,因此本文提出的最终模型包含了 4 层 LSTM 网络层,各层的神经元数量分别为 4, 8, 16 和 32。在每层 LSTM 网络层间采用随机失活方法防止模型过拟合。最后通过全连接层(Dense)输出指定格式的向量,即第二天 96 个时刻的负荷值。

2.4 实验评价指标

为了评估预测的性能,参考国家电网有限公司评价负荷预测指标,设置平均绝对百分比误差 y_{MAPE} 、根均方误差 y_{RMSE} 和预测精度 y_{FA} 三项指标。如式(8)—式(10)所示。

$$y_{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{X_{act}(i) - X_{pred}(i)}{X_{act}(i)} \right| \quad (8)$$

$$y_{RMSE} = \sqrt{\frac{\sum_{i=1}^n (X_{act}(i) - X_{pred}(i))^2}{n}} \quad (9)$$

$$y_{FA} = \left[1 - \frac{|X_{act}(i) - X_{pred}(i)|}{X_{act}(i)} \right] \times 100\% \quad (10)$$

式中: n 为预测总次数; $X_{act}(i)$ 和 $X_{pred}(i)$ 分别为 i 时刻的负荷真实值和预测值。

3 算例分析

为验证本文所提方法的科学性和可靠性,本文实验使用江苏省某市 2015 年至 2017 年电力负荷数据和气象数据 42 万多条作为数据集,选用特征如表 1 所示,构建模型结构如图 3 所示。最后将实验结果与经典的 ARIMA 模型、随机森林模型和 LSTM 网络模型预测结果进行对比分析可知,本文所提模型取得了较好的预测准确率。

3.1 数据处理

1) 异常数据处理

历史负荷数据和气象数据由于通信错误或者数据丢失等,有异常数据存在,它们将影响预测模型的预测精度,需要排除。根据文献[27]提供的解析分析和修正法来识别不良数据,补足缺损的数据。

2) 数据标准化

此次实验采用 min-max 标准化将原始数据 x 进行线性变换,将数据大小约束在 $[0, 1]$, 即

$$x^* = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (11)$$

式中: x^* 为标准化后的值; $x_{\max}$ 为样本数据中的最大值; $x_{\min}$ 为样本数据中的最小值。

3) 训练集和测试集划分

以 2015 年 1 月至 2017 年 5 月负荷数据及气象数据作为训练数据集,以 2017 年的 6 月至 12 月作

为测试数据集。

3.2 实验设置

本文中硬件平台为工作站。处理器为 Intel Xeon E5,内存为 64 GB,固态硬盘容量为 256 GB,4 块 GPU 显卡 GTX1080TI 11G。软件框架结构为基于 Keras 深度学习工具的 Tensorflow 框架,它由 Python 编写而成并可以在 Tensorflow, Theano 以及 CNTK 框架之间进行后端切换,提供高层的神经网络编程接口,能够实现快速的模型构建和实验开发。Keras 提供简洁一致的编程接口,能够帮助用户快速理解神经网络架构,减少代码实现过程中的重复工作。Keras 具有模块化的特点,支持模型层的自由组合和层层叠加。

3.3 实验结果分析

本次实验先采用控制变量法进行逐步的模型调优。通过不断增加 LSTM 网络的层数来测试增加模型深度所起到的预测效果。在固定 CNN 层提取特征不变的情况下,测试不同层数 LSTM 网络层对预测结果的影响。试验结果如表 2 所示,可以发现通过适当地增加 LSTM 网络层来增加模型深度可以提高模型预测能力,但当 LSTM 网络层增加到 5 层时训练误差率上升,表明模型过度学习。

表 2 模型结构组合试验结果
Table 2 Combined testing result of model structure

LSTM 网络层数	训练轮数	训练批次大小	特征数	y_{MAPE}
2	500	512	16	0.028 2
3	500	512	16	0.027 4
4	500	512	16	0.026 5
5	500	512	16	0.029 7

经过上述实验,确定了模型参数和模型结构后,对 CNN-LSTM 网络模型进行训练和验证测试工作。本文对 2017 年 6 月至 12 月连续进行日前短期负荷预测,并计算平均绝对百分比误差与经过参数调优的 ARIMA 方法、随机森林方法和 LSTM 网络模型方法预测结果进行对比,结果显示本文方法在随机单独一天和半年内连续进行日前负荷预测的平均精度均高于其他三种模型,如表 3 所示,其中, $y_{FA, avg}$ 为预测精度的平均值。

表 3 模型预测结果比较
Table 3 Comparison of model prediction results

模型	一天		半年	
	y_{MAPE}	$y_{FA, avg}$	y_{MAPE}	$y_{FA, avg}$
ARIMA	0.021 7	97.82	0.045 2	95.48
随机森林	0.013 7	98.63	0.027 6	97.24
LSTM 网络	0.023 8	97.62	0.019 4	98.06
CNN-LSTM 网络	0.011 1	98.89	0.014 9	98.51

表 4 为不同算法模型验证一天中负荷实际值和

预测值及绝对百分比误差的汇总表。图 4 是算法模型预测值与实际值的折线图,从图中可以看出 4 种算法模型对次日实际负荷预测均有较好的结果。本

文所提方法预测得到的负荷预测曲线精度最高,与实际曲线变化趋势基本一致。

表 4 实际和预测值及绝对百分比误差
Table 4 Practical and predicted values and absolute percentage errors

时间/ h	真实值	CNN-LSTM 网络模型		LSTM 网络模型		ARIMA 模型		随机森林模型	
		预测值	绝对百分比误差	预测值	绝对百分比误差	预测值	绝对百分比误差	预测值	绝对百分比误差
1	12 576.0	12 288.99	2.28	12 660.69	0.67	12 992.13	3.31	12 474.84	0.80
2	12 399.3	12 254.12	1.17	12 564.12	1.33	12 813.19	3.34	12 409.12	0.08
3	12 332.4	12 165.23	1.36	12 419.72	0.71	12 757.47	3.45	12 292.48	0.32
4	12 237.3	12 109.66	1.04	12 308.98	0.59	12 434.70	1.61	12 209.32	0.23
5	12 249.1	12 234.57	0.12	12 318.06	0.56	12 663.41	3.38	12 276.31	0.22
6	12 656.8	12 562.02	0.75	12 671.85	0.12	13 108.46	3.57	12 616.94	0.31
7	13 381.1	13 449.98	0.51	13 263.94	0.88	13 877.41	3.71	13 356.96	0.18
8	14 203.9	14 527.30	2.28	14 110.15	0.66	15 332.99	7.95	14 318.72	0.81
9	15 406.3	15 460.05	0.35	15 064.18	2.22	15 545.05	0.90	15 262.12	0.94
10	15 910.1	15 758.05	0.96	15 448.42	2.90	15 650.80	1.63	15 603.24	1.93
11	15 585.9	15 486.53	0.64	15 006.62	3.72	15 525.08	0.39	15 246.57	2.18
12	14 754.5	15 168.70	2.81	14 288.99	3.16	15 013.01	1.75	14 728.84	0.17
13	15 473.0	15 215.48	1.66	14 941.82	3.43	15 297.12	1.14	15 078.65	2.55
14	15 555.4	15 529.28	0.17	14 989.20	3.64	15 548.63	0.04	15 259.24	1.90
15	15 535.7	15 721.56	1.20	15 000.04	3.45	15 611.45	0.49	15 360.80	1.13
16	15 636.1	15 526.77	0.70	15 061.26	3.68	15 200.66	2.78	15 294.02	2.19
17	15 356.9	15 249.93	0.70	14 999.27	2.33	15 438.31	0.53	15 124.60	1.51
18	15 307.5	15 157.09	0.98	14 930.46	2.46	15 542.01	1.53	15 043.77	1.72
19	15 282.8	15 192.41	0.59	14 850.29	2.83	15 492.88	1.37	15 021.35	1.71
20	14 954.6	15 159.31	1.37	14 576.81	2.53	15 538.71	3.91	14 868.06	0.58
21	14 911.3	14 904.10	0.05	14 466.57	2.98	15 232.93	2.16	14 685.33	1.52
22	14 429.1	14 262.88	1.15	13 875.12	3.84	14 530.44	0.70	14 069.00	2.50
23	13 614.0	13 479.64	0.99	13 203.05	3.02	13 679.72	0.48	13 341.35	2.00
24	12 985.5	12 940.27	0.35	12 616.35	2.84	13 175.21	1.46	12 778.31	1.60




图 4 预测曲线与实际曲线对比图
Fig. 4 Comparison diagram of predicted and practical curves

4 结语

本文针对电力系统短期负荷预测精度日益提高的要求,提出一种基于 CNN-LSTM 网络混合模型的短期负荷预测方法,利用 CNN 处理多源数据提

取有效特征,再通过 LSTM 网络进行时序数据分析,其优势如下。

- 1) 将海量多源数据按时间滑动窗口构造连续特征图作为输入,充分发挥 CNN 模型的潜在特征提取优势,从而挖掘数据中蕴含的更多有效信息。
- 2) 将特征向量以时序序列方式构造并作为 LSTM 网络模型输入数据,LSTM 网络模型能较好地拟合负荷数据的时序性和复杂非线性关系。
- 3) CNN-LSTM 网络混合模型兼顾 CNN 模型和 LSTM 网络模型特点。实验结果表明,与传统短期负荷预测方法相比,本文方法提高了短期负荷预测精度。

本文所用数据未包含负荷类型及各类占比,分析不同地区负荷特性可针对性提高地区负荷预测准确率,后续研究工作将进一步研究负荷特性分类以及模型参数对预测结果影响,研究构建更加轻量化的预测模型,加快模型训练和预测速度,提高负荷预测实时性等。

参考文献

- [1] 康重庆,夏清,刘梅. 电力系统负荷预测[M]. 北京:中国电力出版社,2007.
KANG Chongqing, XIA Qing, LIU Mei. Power system load forecasting[M]. Beijing, China Electric Power Press, 2007.
- [2] MAHMUD M A. Isolated area load forecasting using linear regression analysis: practical approach[J]. Energy and Power Engineering, 2011, 3(4): 547-550.
- [3] OSTERAGOVA E, OSTERTAG O. Forecasting using simple exponential smoothing method [J]. Acta Electrotechnica et Informatica, 2012, 12: 62-66.
- [4] 潘志远,韩学山. 电网节点负荷的立体化预测方法[J]. 电力系统自动化,2012,36(21):47-52.
PAN Zhiyuan, HAN Xueshan. A multi-dimensional method of nodal load forecasting in power grid[J]. Automation of Electric Power Systems, 2012, 36(21): 47-52.
- [5] 王勇,黄国兴,彭道刚. 带反馈的多元线性回归法在电力负荷预测中的应用[J]. 计算机应用与软件,2008(1):82-84.
WANG Yong, HUANG Guoxing, PENG Daogang. Application of multiple linear regression method with feedback in power load forecasting[J]. Computer Application and Software, 2008(1): 82-84.
- [6] BEIRAGHI M, RSNIBSR A M. Discrete fourier transform based approach to forecast monthly peak load[C]// IEEE PES Asia-Pacific Power and Energy Engineering Conference, March 25-28, 2011, Wuhan, China.
- [7] 艾欣,周志宇,魏妍萍,等. 基于自回归积分滑动平均模型的可转移负荷竞价策略[J]. 电力系统自动化,2017,41(20):26-31. DOI:10.7500/AEPS20170119009.
AI Xin, ZHOU Zhiyu, WEI Yanping, et al. Bidding strategy for time-shiftable loads based on autoregressive integrated moving average model [J]. Automation of Electric Power Systems, 2017, 41(20): 26-31. DOI: 10.7500/AEPS20170119009.
- [8] HOR C, WATSON S J, MAJITHIA S, et al. Daily load forecasting and maximum demand estimation using ARIMA and GARCH[C]// IEEE International Conference on Probabilistic Methods Applied to Power Systems, June 11-15, 2006, Stockholm, Sweden.
- [9] 刘洋,许立雄. 适用于海量负荷数据分类的高性能反向传播神经网络算法[J]. 电力系统自动化,2018,42(21):96-103. DOI: 10.7500/AEPS20171215005.
LIU Yang, XU Lixiong. High-performance back propagation neural network algorithm for classification of mass load data[J]. Automation of Electric Power Systems, 2018, 42(21): 96-103. DOI: 10.7500/AEPS20171215005.
- [10] 苏学能,刘天琪,曹鸿谦,等. 基于 Hadoop 架构的多重分布式 BP 神经网络的短期负荷预测方法[J]. 中国电机工程学报,2017,37(17):4966-4973.
SU Xueneng, LIU Tianqi, CAO Hongqian, et al. A multiple distributed BP neural networks approach for short-term load forecasting based on Hadoop framework[J]. Proceedings of the CSEE, 2017, 37(17): 4966-4973.
- [11] 朱海兵,崔玉,熊浩. 基于改进型 BP 神经网络的电网负荷预测[J]. 现代电子技术,2016,39(20):64-66.
ZHU Haibing, CUI Yu, XIONG Hao. Load forecasting based on improved BP neural network [J]. Modern Electronics Technique, 2016, 39(20): 64-66.
- [12] 吴潇雨,和敬涵,张沛,等. 基于灰色投影改进随机森林算法的电力系统短期负荷预测[J]. 电力系统自动化,2015,39(12):50-55.
WU Xiaoyu, HE Jinghan, ZHANG Pei, et al. Power system short-term load forecasting based on improved random forest with grey relation projection[J]. Automation of Electric Power Systems, 2015, 39(12): 50-55.
- [13] 孔祥玉,郑锋,鄂志君,等. 基于深度信念网络的短期负荷预测方法[J]. 电力系统自动化,2018,42(5):133-139. DOI: 10.7500/AEPS20170826002.
KONG Xiangyu, ZHENG Feng, E Zhijun, et al. Short-term load forecasting based on deep belief network[J]. Automation of Electric Power Systems, 2018, 42(5): 133-139. DOI: 10.7500/AEPS20170826002.
- [14] 吴倩红,高军,侯广松,等. 实现影响因素多源异构融合的短期负荷预测支持向量机算法[J]. 电力系统自动化,2016,40(15):67-72.
WU Qianhong, GAO Jun, HOU Guangsong, et al. Short-term load forecasting support vector machine algorithm based on multi-source heterogeneous fusion of load factors [J]. Automation of Electric Power Systems, 2016, 40(15): 67-72.
- [15] 沈百新. 利用专家系统预测地区用电负荷[J]. 电力需求侧管理,2005(2):49-50.
SHEN Baixin. Using expert system to predict the power load in the area [J]. Electronics Demand Side Management, 2005(2): 49-50.
- [16] SUNDERMEYER M, SCHLUTER R, NRY H, et al. LSTM neural networks for Language modeling[C]// Conference of the International Speech Communication Association, September 9-13, 2012, Portland, USA.
- [17] ILYA S, ORIOL V, QUOC O L. Sequence to sequence learning with neural networks [J/OL]. [2018-10-11]. Computation and Language. <https://arxiv.org/abs/1409.3215>.
- [18] MEDENNIKOV I, BULUSHEVA A. LSTM-based language models for spontaneous speech recognition[C]// International Conference on Speech and Computer, June 26-29, 2016, Okayama, Japan.
- [19] 陈卓,孙龙祥. 基于深度学习 LSTM 网络的短期电力负荷预测方法[J/OL]. [2018-01-01]. 电子技术. <http://www.cnki.com.cn/Article/CJFDTotal-DZJS201801011.htm>.
CHEN Zhuo, SUN Longxiang. Short-term electrical load forecasting based on deep learning LSTM networks[J/OL].

- [2018-01-01]. Electronic Technology. <http://www.cnki.com.cn/Article/CJFDTotal-DZJS201801011.htm>.
- [20] 陈亮,王震,王刚. 深度学习框架下 LSTM 网络在短期电力负荷预测中的应用[J]. 电力信息与通信技术, 2017(5): 8-11.
CHEN Liang, WANG Zhen, WANG Gang. Application of LSTM networks in short-term power load forecasting under the deep learning framework[J]. Electric Power ICT, 2017(5): 8-11.
- [21] 贝超,胡珀. 语言先验知识对神经网络模型自然语言处理任务的影响[J]. 中文信息学报, 2017, 31(6): 10-17.
BEI Chao, HU Po. Influence of language prior knowledge on natural language processing task of neural network model[J]. Chinese Journal of Information, 2017, 31(6): 10-17.
- [22] 杜宇. 基于深度机器学习的体态与手势感知计算关键技术研究[D]. 杭州: 浙江大学, 2017.
DU Yu. Research on the key techniques of posture and gesture perception based on depth machine learning[D]. Hangzhou: Zhejiang University, 2017.
- [23] CHEN H, CANIZARES C A, SINGH A. ANN-based short-term load forecasting in electricity markets[C]// Proceedings of the IEEE Power Engineering Society Transmission and Distribution Conference, January 28 - February 1, 2001, Columbus, USA.
- [24] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [25] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
- [26] GRAVES A, MOHAMED A, HINTON G. Speech recognition with deep recurrent neural networks[C]// IEEE International Conference on Acoustics, Speech and Signal Processing, May 26-31, 2013, Vancouver, Canada.
- [27] CHEN Yahong, MU Gang, DUAN Fangli. Identification and management to anomalous data in short term load forecasting [J]. Journal of Northeast China Institute of Electric Power Engineering, 2002, 22(2): 1-5.

陆继翔(1973—),男,通信作者,高级工程师,主要研究方向:人工智能与电网调度。E-mail: lujixiang@sgepri.sgcc.com.cn

张琪培(1993—),男,工程师,主要研究方向:深度学习与电力大数据分析技术。E-mail: zhangqipei@sgepri.sgcc.com.cn

杨志宏(1968—),男,教授级高级工程师,主要研究方向:电网调控自动化和变电站自动化。E-mail: yangzhihong@sgepri.sgcc.com.cn

(编辑 鲁尔姣)

Short-term Load Forecasting Method Based on CNN-LSTM Hybrid Neural Network Model

LU Jixiang^{1,2}, ZHANG Qipei¹, YANG Zhihong^{1,2}, TU Mengfu^{1,2}, LU Jinjun^{1,2}, PENG Hui^{1,2}

- (1. NARI Group Corporation (State Grid Electric Power Research Institute), Nanjing 211106, China;
2. State Key Laboratory of Smart Grid Protection and Control, Nanjing 211106, China)

Abstract: In order to screen out the effective information contained in massive data and improve the accuracy of short-term load forecasting, a hybrid model of short-term load forecasting method based on convolutional neural network (CNN) and long short-term memory (LSTM) network is proposed due to the timing and nonlinear characteristics of load data, which takes massive historical load data, meteorological data, date information and peak-valley electricity price data as input by constructing a continuous feature map of time sliding window. Firstly, CNN is used to extract feature vectors. The feature vectors are constructed as time series and used as input data for LSTM network, which is utilized to forecast the short-term load. The proposed method is used to predict the power load data of an area in Jiangsu province. The experimental results show that the proposed prediction method has higher prediction accuracy than the traditional load forecasting method, the random forest forecasting method and the standard LSTM network forecasting method.

This work is supported by National Key R&D Program of China (No. 2017YFB0902600).

Key words: short-term load forecasting; convolutional neural network (CNN); long short-term memory (LSTM) network; a hybrid model of CNN-LSTM network